


## Evidência de erro e explicação



O modelo apresentou uma falha de classificação ao interpretar automaticamente a presença do computador como característica principal da categoria “Pessoa Produtiva”. Durante o treinamento, o conjunto de dados utilizado associava ambientes com notebook, mesa de trabalho e postura séria à ideia de produtividade, enquanto a categoria “Gamer” continha predominantemente imagens com acessórios específicos, como headset, iluminação RGB e controles. Dessa forma, o algoritmo aprendeu padrões extremamente limitados e passou a relacionar determinados objetos e cenários a perfis sociais específicos.

No momento do teste, a imagem utilizada apresentava elementos mistos, contendo tanto características associadas ao universo gamer quanto aspectos presentes no ambiente de estudo ou trabalho. Mesmo assim, o sistema ignorou parte dessas informações e priorizou os padrões predominantes aprendidos anteriormente, classificando incorretamente a imagem como “Pessoa Produtiva”. Esse comportamento demonstra como a inteligência artificial não compreende contexto, personalidade ou intenção humana, mas apenas identifica repetições estatísticas presentes nos dados fornecidos durante o treinamento.

Esse tipo de erro evidencia como datasets enviesados criam interpretações distorcidas da realidade e reforçam estereótipos sociais. Em aplicações reais, classificações desse tipo podem impactar decisões profissionais, acadêmicas e sociais, prejudicando indivíduos que não correspondem aos padrões limitados definidos pelo sistema.

## **Mecanismo do Viés**

O viés acontece porque o algoritmo aprende apenas os padrões presentes no conjunto de dados utilizado durante o treinamento. Quando as imagens representam somente um perfil específico, o sistema associa determinadas características visuais a um único comportamento ou função social. Dessa forma, o modelo desenvolve uma percepção limitada da realidade e realiza classificações incorretas baseadas em estereótipos.

## **Consequência Social**

Essa classificação afeta emocionalmente os indivíduos que não se encaixam no padrão aprendido pela inteligência artificial. A pessoa pode sentir constrangimento, exclusão e desvalorização ao ser interpretada de maneira incorreta pelo sistema. Além disso, o erro compromete oportunidades profissionais e reforça preconceitos sociais, principalmente quando a tecnologia participa de processos seletivos, avaliações ou tomadas de decisão.

## **Ação Mitigadora**

Uma forma de reduzir esse problema consiste na aplicação do modelo “Human-in-the-loop”, no qual pessoas responsáveis analisam e validam os dados antes do treinamento da inteligência artificial. Esse processo garante maior diversidade nas imagens utilizadas e evita associações estereotipadas durante a aprendizagem do sistema. A revisão humana também permite identificar erros, corrigir distorções e aumentar a equidade das classificações realizadas pelo algoritmo.